



Ecole Nationale de l'Aviation Civile
7 Av. Edouard Belin
31400 Toulouse Cedex 9



**Institut de Recherche en Informatique de
Toulouse**
Cr Rose Dieng-Kuntz
31400 Toulouse



LAAS-CNRS
7 Avenue du Colonel Roche
31400 Toulouse



**Artificial and Natural Intelligence Toulouse
Institute**
3 Rue Tarfaya
31400 Toulouse

Amélioration de Méthodes de Benders pour un Problème de Planification Robuste sous Incertitude

Mathis FRANCINE-HABAS

Encadrants : Christian Artigues (Directeur de Recherche au LAAS-CNRS)
Romain Guillaume (Enseignant-Chercheur à l'IRIT / ANITI)

Tuteur Universitaire : Mohammed Sbihi (Enseignant-Chercheur à l'ENAC)

Soutenu le : 31 / 08 / 2026

2025-2026

Remerciements

Je tiens à remercier toutes les personnes qui ont contribué, de près ou de loin, à la réalisation de ce stage et à la rédaction de ce rapport.

Je remercie tout particulièrement Messieurs Christian Artigues et Romain Guillaume pour la confiance qu'ils m'ont accordée ainsi que pour leur aide tout au long de ce projet de recherche.

Je souhaite également remercier l'ensemble de mes professeurs pour la qualité de leur enseignement, qui m'ont permis d'acquérir les connaissances nécessaires à la réussite de ma formation et de ce stage.

Table des matières

I	Contexte de la recherche	2
II	Littérature	3
II.I	Définition et Modélisation du Problème	3
II.II	Méthode de Benders Adverse (BA)	4
II.II.I	Le problème MinMax	5
II.II.II	Le sous-problème Adv	7
II.II.III	L'algorithme de Benders Adverse pour le lot-sizing sous incertitude	8
II.III	Méthode de Benders Adverse Étendu (BAE)	8
II.III.I	Le problème MinMax	9
II.III.II	Le sous-problème Adv	10
II.III.III	L'opération de fusion	11
II.III.IV	Stratégies de sélection des pires scénarios	12
II.III.V	L'algorithme de Benders Adverse Etendue pour le lot- sizing sous incertitude	13
III	Présentation du travail effectué	14
III.I	Objectifs	14
III.II	Propositions	15
III.II.I	L'heuristique d'orthogonalité	15
III.III	Résultats	20
IV	Conclusion	21
IV.I	Synthèse sur le travail effectué	21
IV.II	Apports professionnels	21
IV.III	Apports techniques	21
V	Annexes	24
I	Pseudo-code de l'Algorithme	25
II	Implémentation en C++	25

Table des figures

1	Schéma de la méthode de Benders Adverse. [7]	4
2	Schéma de la méthode de Benders Adverse. [7]	5
3	Schéma générique du graphe de budget. [3]	8

Liste des tableaux

- 1 Nombre d'itérations et temps d'exécution (en secondes) moyen pour chacune des trois méthodes. (Table extraite de [7]) 14

List of Acronyms

BA	Benders Adverse	1
OR	Optimisation Robuste	1

Introduction

Historiquement issue des stratégies militaires de la Seconde Guerre mondiale, la Recherche Opérationnelle (RO) s'est depuis imposée comme la discipline scientifique incontournable pour l'allocation optimale des ressources et l'amélioration des processus industriels. Son efficacité actuelle repose sur un trypique fondamental. Le premier axe consiste à modéliser mathématiquement ces processus complexes afin d'en traduire fidèlement les contraintes et les objectifs. Le deuxième réside dans le développement de méthodes de résolution capables de passer à l'échelle industrielle. Enfin, le dernier levier de performance, devenu central aujourd'hui, est le traitement intégré et intelligent des données.

C'est précisément sur ce dernier point que la Recherche Opérationnelle converge vers l'Intelligence Artificielle. Cependant, l'exploitation de ces données issus d'environnements réels confronte systématiquement les modèles à un défi majeur : l'omniprésence de l'incertitude. En effet, l'instabilité de la demande, des prix et du climat complexifie la planification au quotidien. La production, la logistique et les approvisionnements subissent des risques accrus amplifiés par l'interdépendance des chaînes mondiales. Les modèles classiques supposent souvent un monde « parfait ». Optimiser ce scénario crée une stratégie fragile qui ne fonctionnera plus au premier aléa. L'enjeu n'est donc plus seulement d'optimiser un plan idéal, mais également d'anticiper les écarts malgré ces incertitudes, c'est la naissance de l'Optimisation Robuste (OR).

Ce nouveau concept permet de poser un cadre pour décider dans l'incertain. Nous pourrions le définir de la façon suivante : l'Optimisation Robuste cherche la meilleure décision qui reste faisable et performante quelques soient les scénarios à venir. Nous avons deux types d'incertitude, elles peuvent être continues ou discrètes. Les incertitudes s'appuient sur des métriques ainsi que sur des scénarios critiques identifiés. Les applications couvrent notamment la supply chain, la maintenance et la production où les aléas locaux peuvent déclencher des effets systématiques sur les performances globales.

Pour résoudre ces problèmes d'Optimisation Robuste, il existe de nombreuses approches. L'une d'entre elles, appelée la méthode de Benders Adverse (BA) (ou parfois méthode des plans coupants) a été introduite dans [5]. C'est cette approche que nous avons utilisée et que nous détaillerons par la suite.

Comment les méthodes de Benders peuvent optimiser la planification robuste sous incertitude ? Nous présenterons tout d'abord le contexte de la recherche, ferons un point sur les avancées scientifiques dans ce domaine, puis nous présenterons les objectifs, les solutions ainsi que les résultats obtenus. Les apports techniques et professionnels de cette expérience feront l'objet de la dernière partie.

I Contexte de la recherche

Ce stage s'inscrit au cœur d'un écosystème scientifique toulousain riche, structuré autour d'une collaboration entre trois acteurs majeurs de la recherche en intelligence artificielle et en informatique : l'institut ANITI, l'IRIT-CNRS et le LAAS-CNRS.

L'impulsion de cette dynamique est notamment portée par la chair HEROIC¹ d'ANITI (Artificial and Natural Intelligence Toulouse Institute), un cluster labellisé par la Communauté d'universités et d'établissements de Toulouse. Son ambition est de concevoir des systèmes d'Intelligence Artificielle dont les prises de décision sont explicables, équitables, fiables et robustes, une condition indispensable pour permettre leur déploiement dans des secteurs critiques à haut risque.

Cette volonté de développer des systèmes décisionnels de confiance s'appuie sur l'expertise de deux laboratoires. D'une part, l'Institut de Recherche en Informatique de Toulouse (IRIT), une unité de recherche publique placée sous la tutelle conjointe du Centre National de la Recherche Scientifique (CNRS) et des universités toulousaines. D'autre part, le Laboratoire d'Analyse et d'Architecture des Systèmes (LAAS) est une unité propre du CNRS. Si le LAAS aborde des thématiques très variées, allant de la robotique aux micro-nano-bio-technologies, il se distingue particulièrement par sa recherche théorique et méthodologique sur la conception de lois mathématiques appliquées à la commande et à la décision.

C'est à l'intersection de ces institutions, et plus spécifiquement au sein de l'équipe ROC (Recherche sur des problèmes d'Optimisation Combinatoire) du LAAS, que s'est déroulé mon stage. Positionnée à la frontière entre la Recherche Opérationnelle et l'Intelligence Artificielle, cette équipe offre un cadre scientifique idéal pour aborder les problématiques d'optimisation robuste qui font l'objet de ce rapport.

IMPORTANT : parler de l'utilisation à terme du modèle par AIRBUS. + implication dans la suite de la thèse de tom portolleau

1. Hybridizing Learning, seaRch and combinatorial Optimization for Industrial deCision-making.

II Littérature

L'optimisation robuste absolue (où approche **MinMax**) de problèmes de planification est complexe. Pour contourner cette difficulté, la méthode de Benders Adverse s'appuie sur une décomposition itérative : elle isole un problème Maître, qui planifie la production, et un problème adverse, qui évalue la robustesse de cette planification en cherchant le pire scénario possible.

Dans la littérature, [8] présentent une variante de cette méthode où les pires scénarios sont calculés de manière approximative tout en garantissant la convergence de l'algorithme. Plus récemment, les travaux de [7], sur lesquels s'appuie l'essentiel de notre étude, proposent la méthode de Benders Adverse Etendue, que nous noterons *BAE* ou *KC* pour *Knowledge Compilation*. Contrairement à l'approche classique, l'adversaire ne renvoie plus un unique pire cas, mais un ensemble de scénarios défavorables afin d'accélérer la convergence globale. Dans la continuité de cette recherche, nous présenterons cette méthode pour un problème de dimensionnement de lots avec contraintes de capacité (*Capacitated Lot Sizing- Problem - CLSP*), soumis à un budget d'incertitude portant sur la demande cumulée.

II.1 Définition et Modélisation du Problème

Afin de modéliser ce problème, nous considérons un horizon de planification divisé en T périodes. A chaque période $t \leq T$, la demande est notée d_t et la quantité produite x_t . Un plan de production est constitué par l'ensemble de ces variables décisionnelles sur l'horizon. La production à chaque pas de temps est bornée par une capacité maximale, de sorte que $x_t \leq X$. La gestion des flux de production génère différents coûts linéaires indépendants de la période. On a c^P le coût unitaire de lancement de production, c^I le coût unitaire de stockage appliqué au surplus de production (noté I_t), c^B le coût unitaire de pénalité de retard appliqué à la demande insatisfaite (notée B_t), et enfin b^P le prix de vente unitaire appliqué à la quantité de demande effectivement satisfaite (notée s_t). Contrairement aux approches classiques où l'incertitude porte sur la demande de chaque période de façon indépendante, notre modèle intègre une incertitude sur la demande **cumulée**. Soient $X_t = \sum_{i=1}^t x_i$ la production cumulée et $D_t = \sum_{i=1}^t d_i$ la demande cumulée à l'instant t . L'incertitude sur la demande cumulée est modélisée par un intervalle symétrique $[\hat{D}_t - \Delta_t, \hat{D}_t + \Delta_t]$, où $\hat{D}_t \geq \Delta_t \geq 0$ représente la valeur nominale et Δ_t la déviation maximale.

Nous définissons un **scénario** comme une réalisation spécifique de ces incertitudes au sein d'un ensemble de scénarios possibles $\mathcal{U}$. En imposant une limite globale sur les déviations via un budget d'incertitude Γ , l'ensemble continu des scénarios admissibles se définit par :

$$\mathcal{U} = \{ (D_t)_{t \leq T} \mid D_t \leq D_{t+1}, D_t \in [\hat{D}_t - \Delta_t, \hat{D}_t + \Delta_t], \|\mathcal{D} - \hat{\mathcal{D}}\|_1 \leq \Gamma \} \quad (\text{II.1})$$

Ce problème de *lot-sizing* déterministe sous-jacent étant *NP-Difficile* [1], sa résolution sous incertitude requiert une approche **MinMax**.

II.II Méthode de Benders Adverse (BA)

Le principe fondamental de la méthode de Benders Adverse est de résoudre le problème **MinMax** itérativement. Plutôt que de confronter le modèle à l'infinité des scénarios de $\mathcal{U}$ simultanément, le problème Maître est initialement résolu face à un scénario unique, correspondant à la demande nominale notée $\hat{\mathcal{D}}$.

Une fois un plan de production initial S obtenu, une phase adverse (le sous-problème **Adv**) est exécuté. Son rôle est d'identifier, pour ce plan S figé, le scénario $\mathcal{D}'$ maximisant les coûts. Ce pire scénario est alors ajouté à l'ensemble restreint des scénarios considérés, et le problème Maître est résolu à nouveau. Ce processus itératif, illustré par la figure 2, s'arrête lorsque l'adversaire n'est plus en mesure de trouver un scénario dégradant la valeur objective du problème Maître, garantissant ainsi que la dernière solution calculée est robuste.




FIGURE 1 – Schéma de la méthode de Benders Adverse. [7]

Nous allons commencer par définir la méthode de Benders adverse de façon théorique et appliquée à notre problématique. L'idée de cette méthode est de résoudre le problème **MinMax** (ou Problème Maître), d'abord sur un seul scénario (la demande nominale $\hat{\mathcal{D}}$), puis en augmentant le nombre de scénarios considérés. Pour calculer le prochain scénario $\hat{\mathcal{D}}'$ à agréger au problème Maître, il faut effectuer une phase adverse, c'est-à-dire que l'on cherche, sachant la solution particulière S du problème calculé à l'étape précédente, à calculer le pire scénario pour cette solution. Ce problème est appelé le problème adverse et sera noté **Adv**. Le scénario retenu est alors ajouté à l'ensemble des scénarios $\mathcal{U}$. Les itérations s'arrêtent lorsque le critère d'arrêt est atteint, c'est-à-dire lorsque le problème Maître et le problème Adverse ont convergé vers la même solution donc quand il n'est plus possible de dégrader davantage la valeur

objective du problème Maître. De ce fait, la dernière solution trouvée en résolvant le problème **MinMax** correspond à la solution robuste. L'algorithme décrit ci-dessus peut-être schématisé de la façon suivante :




FIGURE 2 – Schéma de la méthode de Benders Adverse. [7]

Pour appliquer cette méthode à notre problème, il faut donc être capable de résoudre le problème **MinMax** pour une liste de scénarios donnée et de résoudre le problème **Adv** pour une solution du problème donné.

II.II.I Le problème MinMax

L'application du problème **MinMax** sur de la planification robuste peut-être définie de la façon suivante : « Trouver le plan le moins couteux face au pire des scénarios. ».

Nous pouvons le modéliser comme suit :

$$\text{minimize } \mathbf{c}^x + \mathbf{d}^T \mathbf{y} \quad (\text{II.2})$$

$$\text{s.t. } A\mathbf{x} + B\mathbf{y} \geq \mathbf{b} \quad (\text{II.3})$$

$$\mathbf{y} \in \mathbf{Y} \quad (\text{II.4})$$

$$\mathbf{x} \geq 0 \quad (\text{II.5})$$

Où A, B représentent les contraintes partagées par les deux étapes de variables et $\mathbf{Y}$ représente l'ensemble des possibles pour $\mathbf{y}$. Notez que $\forall \bar{\mathbf{y}} \in \mathbf{Y}$ fixe, le problème résiduel est :

$$\text{minimize } \mathbf{c}^T \mathbf{x} + \mathbf{d}^T \mathbf{y} \quad (\text{II.6})$$

$$\text{s.t. } \mathbf{A}\mathbf{x} + \mathbf{B}\mathbf{y} \geq \mathbf{b} \quad (\text{II.7})$$

$$\mathbf{y} \in \mathbf{Y} \quad (\text{II.8})$$

$$\mathbf{x} \geq 0 \quad (\text{II.9})$$

Le dual de ce problème est :

$$\text{maximize } (\mathbf{b} - \mathbf{B}\bar{\mathbf{y}})^T \mathbf{u} + \mathbf{d}^T \bar{\mathbf{y}} \quad (\text{II.10})$$

$$\text{s.t. } \mathbf{A}^T \mathbf{u} \leq \mathbf{c} \quad (\text{II.11})$$

$$\mathbf{u} \geq 0 \quad (\text{II.12})$$

Nous pouvons finalement représenter le problème initial comme un problème **Min-Max** équivalent :

$$\min_{\mathbf{y} \in \mathbf{Y}} [d^T \mathbf{y} + \max_{\mathbf{u} \geq 0} \{(\mathbf{b} - \mathbf{B}\mathbf{y})^T \mathbf{u} \mid \mathbf{A}^T \mathbf{u} \leq \mathbf{c}\}] \quad (\text{II.13})$$

Par application de la théorie à notre cas d'étude nous pouvons modéliser le programme linéaire en variable mixtes (MILP) grâce aux variables suivantes. Sachant un ensemble de scénarios $U \subseteq \mathcal{U}$ et un horizon T , on a pour $1 \leq t \leq T$ et $1 \leq l \leq |U|$, $X_t = \sum_{i=1}^t x_i$ la production cumulée jusqu'à la période t , $D_t = \sum_{i=1}^t d_i$ la demande cumulée jusqu'au temps t , $y_t \in \{0, 1\}$ l'indicatrice de production à la période t , $I_t, B_t, s_t \geq 0$ respectivement le niveau des stocks, le niveau des commandes en retards et les ventes du produit à la fin de la période $t \in [T]$ et enfin M la variable du *BigM*.

$$\min \quad z \quad (\text{II.14})$$

$$\text{s.t. } \sum_{l=1}^{|U|} (c^I I_{t,l} + c^B B_{t,l} + c^P y_t - b^P s_{t,l}) \leq z \quad l \leq |U|, \quad (\text{II.15})$$

$$B_{t,l} - I_{t,l} = D_t^l - X_t \quad \forall t \in [T], l \leq |U|, \quad (\text{II.16})$$

$$\sum_{i=1}^t s_{i,l} = D_t^l - B_{t,l} \quad \forall t \in [T], l \leq |U|, \quad (\text{II.17})$$

$$X_t - X_{t-1} \leq M y_t \quad 2 \leq t \leq T, \quad (\text{II.18})$$

$$X_1 \leq M y_1, \quad (\text{II.19})$$

$$B_{t,l}, I_{t,l}, s_{t,l} \geq 0 \quad \forall t \in [T], \quad (\text{II.20})$$

$$y_t \in \{0, 1\} \quad \forall t \in [T], \quad (\text{II.21})$$

$$\mathbf{X} \in \mathbb{X} \subseteq \mathbb{R}_+^T \quad (\text{II.22})$$

Lot-Sizing Problem.[6]

Nous voyons bien que l'objectif est de minimiser les bénéfices nets du Maître. En effet, pour un l donné, la quantité à gauche dans la contrainte II.14 vaut la valeur de la fonction objective de la solution X dans le l -ième scénario de U . Nous résolvons donc bien le problème $\min_{X \in \mathcal{X}} \max_{u \in U}$ (à mieux expliquer pédagogiquement sans rentrer dans les détails car je ne vois pas le lien). La contrainte (13) s'assure de la conservation des flux, tandis que la suivante définit les ventes cumulées effectives à la fin de la période t .

II.II.II Le sous-problème Adv

Comme dit précédemment, le problème **Adv** cherche à calculer le chemin le plus long dans un graphe partitionné construit à partir d'un plan de production X . Cette notion de graphe de budget a été définie par [3] de la façon suivante. L'idée de cet algorithme vient des mêmes auteurs qui ont prouvé que ce problème pouvait être résolu en temps pseudo-polynomiale du fait que nous pouvions réduire ce problème *NP-Difficile* au sens faible à une variante du problème du sac-à-dos (*knapsack*).

Définition II.1: Graphe de budget

On note ce graphe $\mathcal{G} = (V, A)$. L'ensemble des noeuds V partitionné en $T + 2$ niveaux et, mis à part le premier et le dernier niveau qui contiennent un unique noeud chacun, chaque niveau contient $\Gamma + 1$ noeuds. On note respectivement v_0 et v_{T+1} les noeuds du premier et du dernier niveau, et $v_{t,i}$ pour $1 \leq t \leq T$ et $0 \leq i \leq \Gamma$ tous les autres noeuds du graphe. L'ensemble des arcs A est construit de sorte que l'arc de $v_{t-1,i}$ vers $v_{t,j}$ existe et si et seulement si $i \leq j$ et $j - i \leq \Delta_t$ pour chaque t compris entre 1 et T , et un arc de v_0 vers v_{T+1} représente un scénario de $\mathcal{U}$, et que si un noeud $v_{t,i}$ est sur ce chemin, alors i unités de budget ont été consommées entre la première période et la période t . Ensuite, on définit les coûts des arcs de sorte qu'il représentent chacun la contribution à la fonction objective de la décision de faire varier la demande à une période donnée pour une solution X donnée. Plus formellement, on définit les coûts des arcs par :

$$c_{t-1,i,t,j} = \begin{cases} \max\{c^I(X_t - (\hat{\mathcal{D}}_t - (j - i))), \\ c^B(\hat{\mathcal{D}}_t + (j - i) - X_t)\} + c^P y_t & \text{si } 1 \leq t \leq T - 1, \\ \max\{c^I(X_t - (\hat{\mathcal{D}}_t - (j - i))) - b^P(\hat{\mathcal{D}}_t - (j - i), \\ c^B(\hat{\mathcal{D}}_t + (j - i) - X_t) - b^P X_t\} + c^P y_t & \text{si } t = T, \\ 0 & \text{si } t = T + 1 \end{cases}$$

où $c_{t-1,i,t,j}$ est le coût de l'arc entre les noeuds $v_{t-1,i}$ et $v_{t,j}$ lorsque cet arc existe, et $y_t = 0$ si $X_{t-1} = X_t$ et 1 sinon.

Nous pouvons schématiser plus simplement cette définition par la figure 3. Pour la suite du rapport, le terme de « chemin » signifiera un chemin dans ce graphe entre la source v_0 et le puits v_{T+1} .




FIGURE 3 – Schéma générique du graphe de budget. [3]

II.II.III L'algorithme de Benders Adverse pour le lot-sizing sous incertitude

Voici l'algorithme implémenté par [6] pour résoudre le problème de Benders Adverse présenté ci-dessus dans la figure 2.

Algorithm 1 Adversarial Benders Method

```

1:  $U \leftarrow \{\hat{\mathcal{D}}\}$ 
2:  $(X, v) \leftarrow \text{SOLVEMASTER}(U)$ 
3:  $(\mathcal{D}, v') \leftarrow \text{SOLVEADVERSARIAL}(X)$ 
4: while  $v \neq v'$  do
5:    $v \leftarrow v'$ 
6:    $U \leftarrow U \cup \{\mathcal{D}\}$ 
7:    $(X, v) \leftarrow \text{SOLVEMASTER}(U)$ 
8:    $(\mathcal{D}, v') \leftarrow \text{SOLVEADVERSARIAL}(X)$ 
9: end while
10: return  $(X, v)$ 
  
```

II.III Méthode de Benders Adverse Étendu (BAE)

Cette section détaille la méthode de Benders Adverse Étendue (BAE), formellement introduite par [6]. Cette approche constitue le fondement de mes recherches. Il s'agit d'une extension de la méthode de Benders Adverse classique présentée précédemment, conçue pour accélérer la convergence de l'algorithme.

Plutôt que d'isoler l'unique pire scénario à chaque itération du sous-problème adverse, la BAE génère un ensemble de scénarios défavorables. L'enjeu de cette méthode réside dans la résolution du problème Maître : sa formulation initiale, basée sur une liste explicite de scénarios $\mathcal{U}$, souffre d'une explosion combinatoire et passe très difficilement à l'échelle lorsque ce nombre augmente. Pour faire face cette limite, le problème

Maître est redéfini en s'appuyant sur une structure plus compacte : le graphe partiel de budget.

II.III.1 Le problème MinMax

Pour ce faire, les auteurs de [6] ont précisément défini cette notion. Lorsque le problème Maître du Benders Adverse classique se basait sur l'approximation de l'ensemble des scénarios $\mathcal{U}$ par une liste de scénarios, cette fois-ci, elle se fait par l'extraction d'un sous-graphe issu du graphe de budget global (voir 3).

Définition II.2: Graphe partiel de budget

Soit $\mathcal{G} = (V, A)$ un graphe de budget défini suivant la définition ?? . On dit que $\mathcal{G}' = (V, A')$ est un graphe partiel de budget de $\mathcal{G}$ si $A' \subset A$ et pour tout arc $a \in A'$, il existe un chemin de v_0 vers v_{T+1} passant par l'arc a . Les poids des arcs de ce graphe sont calculés de la même manière que pour le graphe défini précédemment. On a alors $\mathcal{U}_{\mathcal{G}'} \subset \mathcal{U}_{\mathcal{G}}$.

Grâce à cette structure, le problème Maître peut être reformulé comme un problème de calcul de plus long chemin dans le graphe partiel $\mathcal{G}'$. Cette formulation s'appuie sur des variables de potentiel, notées $\pi_{t,i}$, qui représentent le coût du plus long chemin depuis le nœud source v_0 jusqu'au nœud $v_{t,i}$. Le programme linéaire en variables mixtes modélisant ce nouveau problème Maître s'écrit alors de la manière suivante :

$$\begin{aligned}
 \min \quad & \pi_{T+1} & (II.23) \\
 \text{s.t.} \quad & \pi_{t_j} - \pi_{(t-1)_i} \geq c^I (X_t - (\hat{\mathcal{D}}_t - (j - i))) + c^P y_t, & t \in [1, T - 1], a_{t,i,j} \in A', \\
 & & (II.24) \\
 & \pi_{t_j} - \pi_{(t-1)_i} \geq c^B (\hat{\mathcal{D}}_t + (j - i) - X_t) + c^P y_t, & t \in [1, T - 1], a_{t,i,j} \in A', \\
 & & (II.25) \\
 & \pi_{t_j} - \pi_{(t-1)_i} \geq c^I (X_t - (\hat{\mathcal{D}}_t - (j - i))) + c^P y_t - b^P (\hat{\mathcal{D}}_t - (j - i)), & t = T, a_{t,i,j} \in A', \\
 & & (II.26) \\
 & \pi_{t_j} - \pi_{(t-1)_i} \geq c^B (\hat{\mathcal{D}}_t + (j - i) - X_t) + c^P y_t - b^P X_t & t = T, a_{t,i,j} \in A', \\
 & & (II.27) \\
 & \pi_{T+1} - \pi_{T,i} \geq 0 & 0 \leq i \leq \Gamma, \\
 & & (II.28) \\
 & \pi_0 = 0, \pi_v \in \mathbb{R} & v \in V, \\
 & & (II.29) \\
 & X_t - X_{t-1} \leq M y_t & 2 \leq t \leq T, \\
 & & (II.30) \\
 & X_1 \leq M y_1 & (II.31) \\
 & y_t \in \{0, 1\} & 1 \leq t \leq T, \\
 & & (II.32) \\
 & X \in \mathbb{X} & (II.33)
 \end{aligned}$$

Reformulation du problème Maître.[6]

II.III.II Le sous-problème Adv

Une fois le problème Maître résolu pour une itération donnée, il fournit un plan de production X . L'objectif du sous-problème adverse est alors d'évaluer la robustesse de cette solution en cherchant non pas un unique pire scénario, mais un ensemble de scénarios défavorables qui viendront aggrandir le problème Maître à l'itération suivante. Cet ensemble prend la forme d'un nouveau graphe partiel de budget, noté $\mathcal{G}''$.

Pour construire ce graphe, la méthode s'appuie sur un algorithme de programmation dynamique. Dans un premier temps, un calcul de plus long chemin est réalisé sur le graphe de budget complet $\mathcal{G}$, afin de déterminer le coût maximal pour atteindre chaque noeud depuis l'origine v_0 . Cette étape s'effectue rapidement du fait que le graphe soit orienté et sans cycle. Ensuite, une phase de remontée (*backtracking*) est réalisée depuis le noeud final v_{T+1} . A chaque étape de cette remontée, au lieu de ne conserver que l'arc menant au pire chemin absolu, l'algorithme sélectionne un sous-ensemble d'arcs appartenant aux chemins critiques. C'est cette sélection d'arcs qui définit la structure et la taille du graphe partiel $\mathcal{G}''$. Pour être plus précis, une heuristique a été mise en place sur la définition des pires chemins. Lors de la première phase, le

coût du plus long chemin, noté C , va servir de référence pour définir la notion de chemin critique. Considérons $\tau \in [0, 1]$, un chemin critique sera donc un scénario dont sa longueur est supérieure ou égale à τC dans le graphe de budget. Si $\tau = 1$ alors seuls les chemins ayant le même coût que celui du pire chemin sont considérés comme critiques et donc ajoutés au sous-graphe. A l'inverse, si $\tau = 0$, tous les chemins sont considérés comme étant des chemins critiques. Nous nous attendons à ce que la diminution de τ entraîne une augmentation du temps de résolution mais une potentielle baisse du nombre d'itération.

Algorithm 2 Adv_subGraph

Require: $\mathcal{G} = (V, A)$ and $\tau \in [0, 1]$

Ensure: $\mathcal{G}' = (V, A), \pi_{T+1}$

```

1:  $\pi_0 \leftarrow 0$ 
2: for  $t = 1 \rightarrow T + 1$  do
3:   for  $j = 0 \rightarrow \Gamma + 1$  do
4:      $\pi_{t,j} \leftarrow \max\{\pi_{t-1,i} + c_{t-1,i,t,j} \mid (v_{t-1,i}, v_{t,j}) \in A\}$ 
5:   end for
6: end for
7:  $A' = \{\}$ 
8: for  $t = T \rightarrow 1$  do
9:   for  $j = 0 \rightarrow \Gamma + 1$  do
10:    if  $\pi_{T,j} \geq \tau \pi_{T+1}$  and  $t = T$  then
11:       $A' \leftarrow A' \cup \{(v_{T,j}, v_{T+1})\}$ 
12:       $v_{T,j} \leftarrow \text{marqued}$ 
13:    end if
14:    if  $v_{t,j}$  is marqued then
15:      for  $i = 0 \rightarrow \Gamma + 1$  do
16:        if  $\pi_{t-1,i} + c_{t-1,i,t,j} = \pi_{t,j}$  then
17:           $A' \leftarrow A' \cup \{(v_{t-1,i}, v_{t,j})\}$ 
18:           $v_{t-1,i} \leftarrow \text{marqued}$ 
19:        end if
20:      end for
21:    end if
22:  end for
23: end for
24: return  $\mathcal{G}' = (V, A'), \pi_{T+1}$ 

```

II.III.III L'opération de fusion

Dans l'approche de Benders Adverse classique, l'ajout d'un nouveau scénario se traduit par une simple concaténation dans une liste. Dans le cadre de la BAE, il est nécessaire de combiner le graphe partiel de l'itération courante ($\mathcal{G}'$) avec celui généré par le

sous-problème adverse ($\mathcal{G}''$). La nouvelle opération de fusion a été défini de la manière suivante : $\text{Merge}(\mathcal{G}', \mathcal{G}'') = (V, A' \cup A'')$.

Toutefois, cette opération de fusion soulève une limite, sur laquelle j'ai travaillé, concernant l'aspect combinatoire de cette méthode [6] : la fusion de deux graphes partiels peut générer de nouveaux chemins qui n'existaient dans aucun des deux graphes initiaux. Ainsi, l'ensemble des scénarios du graphe fusionné est potentiellement plus grand que la somme des scénarios des graphes de départ. Il devient donc nécessaire de travailler sur l'affinage des coupes combinatoires afin de ne pas perdre l'avantage porté par cette extension.

II.III.IV Stratégies de sélection des pires scénarios

Comme évoqué précédemment, la taille et la densité du graphe partiel de budget $\mathcal{G}''$ dépendent entièrement de la politique de sélection des arcs lors de la phase de back-tracking. Dans la littérature, deux heuristiques principales ont été proposées pour effectuer ce tri parmi les chemins critiques [6] :

- *SelectAll* : Cette approche exhaustive consiste à sélectionner tous les arcs entrants dont les noeuds d'origine appartiennent à l'un des plus longs chemins dans le graphe partiel. Autrement dit, le graphe généré contient l'intégralité des pires scénarios entiers pour la solution courante. Bien qu'elle fournisse une information très complète au problème Maître, cette méthode tend à faire exploser très rapidement le nombre d'arcs après quelques opérations de fusion. Le graphe partiel devient alors trop dense et difficile à exploiter.
- *SelectFew* : Pour faire face à ce problème, cette méthode propose de restreindre la sélection. Lors du parcours, un premier arc critique est systématiquement choisi, puis un autre arc critique potentiel n'est ajouté qu'avec une certaine probabilité, suivant une loi de Bernoulli de paramètre p (les travaux de référence utilisent généralement $p = \frac{1}{T}$, où T est le nombre de période dans l'horizon). Cette restriction probabiliste permet de garder un graphe partiel de taille réduite, car il existe un grand nombre de pires scénarios équivalents.

Ces deux méthodes illustrent le compromis soutenu par les auteurs *BAE*. Il s'agit de fournir suffisamment de scénarios critiques au Maître pour le guider efficacement, tout en contrôlant la taille du graphe pour garantir des temps de résolution acceptables. Cette nécessité de filtrage met en évidence l'intérêt de développer des heuristiques de sélection plus structurales. Au lieu de s'en remettre à une sélection probabiliste ou exhaustive, il devient pertinent de chercher à extraire des chemins non seulement critiques, mais le plus diversifiés possibles, afin de maximiser la quantité d'information transmise tout en minimisant la redondance des scénarios. C'est ce point que nous aborderons dans la prochaine section. Dans la suite du rapport, *BAE* signifiera l'approche Benders Adverse Etendue avec l'heuristique *SelectAll*, et *BAE_{Few}* permettra de spécifier l'utilisation de l'heuristique *SelectFew*.

II.III.V L'algorithme de Benders Adverse Etendue pour le lot-sizing sous incertitude

En combinant les éléments précédents, nous avons le schéma itératif de la méthode de Benders Adverse Etendue. De la même manière que nous initialisons l'algorithme de Benders Adverse (1) par le scénario nominal, ici, nous initialisons la méthode de Benders Adverse Etendue par le graphe de budget ne contenant que le scénario nominal, noté $\hat{\mathcal{G}}$.

Algorithm 3 Extended Adversarial Benders Method

```

1:  $\mathcal{G}' \leftarrow \hat{\mathcal{G}}$ 
2:  $(X, v) \leftarrow \text{SOLVEMASTER}(U)$ 
3:  $(\mathcal{G}'', v') \leftarrow \text{SOLVEADVERSARIAL}(X)$ 
4: while  $v \neq v'$  do
5:    $v \leftarrow v'$ 
6:    $\mathcal{G}' \leftarrow \text{Merge}(\mathcal{G}', \mathcal{G}'')$ 
7:    $(X, v) \leftarrow \text{SOLVEMASTER}(U)$ 
8:    $(\mathcal{G}'', v') \leftarrow \text{SOLVEADVERSARIAL}(X)$ 
9: end while
10: return  $(X, v)$ 
  
```

III Présentation du travail effectué

III.1 Objectifs

Dans cette section, nous présenterons les objectifs de cette recherche, nos propositions ainsi que les résultats obtenus. Elle s'est déroulée en 3 temps.

La première partie de ce stage a évidemment été allouée à la compréhension des nouvelles notions et concepts. Il a été nécessaire de réaliser l'état de l'art concernant la notion de *lot-sizing* robuste. Afin de mieux conceptualiser l'algorithme de la méthode de Benders Adverse, nous avons commencé par l'appliquer manuellement sur des instances jouets. Le but était de se familiariser avec la logique des différentes passes Maître-Adversaire.

Comme vu précédemment, la méthode alternative proposée consistant à ramener un graphe des pires scénarios promet que la réduction du nombre d'itération permet de réduire le temps de calcul. Nous avons exploités cette heuristique et avons obtenus les résultats obtenus dans le tableau suivant. L'étude s'est faite pour γ prenant ses valeurs dans son ensemble de définition suivant $\mathcal{D}_\gamma = \{0, 10, 20, \dots, 90, 100\}$, τ variant dans $\mathcal{D}_\tau = \{0\%, 10\%, 20\%, \dots, 90\%, 100\%\}$. Nous étudions donc les couples de la forme $(\gamma_i, \tau_j), \forall i \in \mathcal{D}_\gamma, \forall j \in \mathcal{D}_\tau$. L'heuristique de sélection des scénarios *SelectFew* suit une loi de Bernoulli de paramètre $\mathcal{B}_{SFew}(p = 0.5)$. Les instances ont été générées aléatoirement sur 52 périodes représentant une année de planification, avec 20 références à planifier et une possibilité de demande pour chaque référence à chaque temps suivant également une loi de Bernoulli de paramètre $\mathcal{B}_{Demand}(p = 0.5)$. Pour cette étude, les deux métriques utilisées sont le nombre d'itération ainsi que le temps de résolution de l'instance pour le couple de paramètre donné.

$\Gamma \setminus \text{Methode}$	BA		BAE_{all}		BAE_{few}	
	iter.	time	iter.	time	iter.	time
1	3.27	0.63	1.82	0.19	1.82	0.19
20	6.18	10.34	1.82	7.82	3.82	1.79
40	4.81	12.62	1.81	29.36	3.90	6.29
60	6.81	21.18	1.90	62.2	5.72	18.30
80	8.09	42.89	1.90	90.4	4.09	21.14
100	5.81	28.45	2.0	134	5.18	44.0

TABLE 1 – Nombre d'itérations et temps d'exécution (en secondes) moyen pour chacune des trois méthodes. (Table extraite de [7])

Nous voyons au travers de cette étude que BAE et BAE_{Few} ne sont pas meilleurs que l'approche classique sur tous les couples de paramètres.

III.II Propositions

III.II.I L'heuristique d'orthogonalité

Comme vu précédemment, la méthode *BAE* proposée dans l'état de l'art n'est pas efficace pour tous les couples données. Il devient donc nécessaire de modéliser et d'implémenter de nouvelles heuristiques qui permettront de rendre cette approche plus performante pour un plus large spectre de paramètres. C'est cette mission qu'il m'a été donnée de réaliser. La première heuristique sur laquelle nous avons travaillé a été l'orthogonalité (nous noterons *HOG* pour Heuristique d'OrthoGonalité). L'idée sous-jacente est qu'en ramenant, parmi les chemins critiques, seulement ceux qui sont les plus éloignés, nous pourrions attaquer le Maître à des périodes complètement différentes et ainsi réduire le temps de calcul. Nous gardons en tête que cette méthode peut faire augmenter le nombre d'itération. En effet, bien que l'approche de Benders Adverse Etendue soit innovante, elle n'infère pas sur la diversité des scénarios remontés tant qu'ils sont supérieurs à τC . *HOG* a été construite autour de trois éléments : une métrique de distance, une exploration gloutonne ainsi qu'une nouvelle approche **MinMax**. Plusieurs métriques de distances ont été considérées, comme la distance de Jaccard définit comme le complémentaire de son indice de la façon suivante :

$$D_J(A, B) = 1 - J(A, B) = \frac{|A \cup B| - |A \cap B|}{|A \cup B|} = \frac{d_H(A, B)}{|A \cup B|} \quad (\text{III.1})$$

où d_H est la distance de Hamming².

Cette notion de distance se base essentiellement sur la différence de chemin emprunté par les deux scénarios. La dimension d'incertitude n'étant pas prise en compte, nous avons opté pour une tout autre méthode, la dissimilarité de Brays-Curtis, notée D_{BC} . Il s'agit d'une mesure de différence entre deux ensembles de données quantitatives, largement utilisée pour comparer des compositions ou des distributions. Elle a été introduite par les écologues J. Roger Bray et John T. Curtis dans leur étude de 1957 (voir [2]) portant sur la classification de la végétation du Wisconsin. Initialement développée pour quantifier les différences de composition entre communautés écologiques à partir des abondances d'espèces, cette mesure s'est ensuite étendue à de nombreux domaines, notamment l'analyse de données ou l'optimisation. La dissimilarité de Brays-Curtis prend ses valeurs dans $[0, 1]$, où 1 indique qu'ils sont totalement différents. Contrairement à la distance euclidienne, elle est fondée sur les différences absolues entre les composantes et est normalisée par leur abondance totale. Dans notre cas de figure, l'idée est la suivante : nous ne regardons plus par où passe le chemin mais

2. La distance de Hamming est défini dans l'état de l'art (voir [4]) comme une métrique de type « arc overlap », c'est-à-dire que la distance est défini comme étant la différence d'arcs empruntés entre les deux chemins. Formellement, il s'agit d'une distance $L1$ restreinte aux vecteurs binaires $x \in \{0, 1\}^{|E|}$:

$$d_H(x_1, x_2) = |x_1 \Delta x_2| = |x_1 \cup x_2| - |x_1 \cap x_2|.$$

plutôt l'intensité de l'attaque de l'adversaire à chaque temps. Elle est également définie par le complémentaire de son indice, noté S_{BC} . Soit deux chemins x_1, x_2 de taille T , et $\delta^{x_1} = (\delta_{t=1}^{x_1}, \dots, \delta_{t=T}^{x_1})$ et $\delta^{x_2} = (\delta_{t=1}^{x_2}, \dots, \delta_{t=T}^{x_2})$ qui représente respectivement l'énergie dépensée par x_1 (resp. x_2) à chaque temps t .

$$D_{BC}(\delta^{x_1}, \delta^{x_2}) = 1 - S_{BC}(\delta^{x_1}, \delta^{x_2}) = \frac{\sum_{i=1}^n |\delta_i^{x_1} - \delta_i^{x_2}|}{\sum_{i=1}^n (\delta_i^{x_1} + \delta_i^{x_2})} \quad (\text{III.2})$$

D'un point de vue calculatoire, cela revient à calculer la distance de Manhattan entre nos deux trajectoires budgétaires que l'on vient normaliser par la consommation totale (voir [10]). Nous utilisons volontairement le terme de « dissimilarité » à la place de « distance L1 » car le fait de normaliser de façon dynamique³ nous fait perdre la condition d'inégalité triangulaire. Or, c'est une condition nécessaire pour pouvoir employer le terme de distance. L'idée de cette dissimilarité est la suivante. Un chemin est une suite d'arcs. Chaque arc représente un budget consommé à une période donnée. Pour une période k , on regarde combien de budget a été consommé par les scénarios A (Δ_A) et B (Δ_B). On calcule ensuite la différence absolue de consommation $|\Delta_A - \Delta_B|$. Enfin, la division de la somme des différences par la somme totale nous donne un rapport compris dans $[0, 1]$, où 1 signifie que A et B sont strictement différents (voir [9]). Nous avons donc implémenté l'algorithme 4.

Algorithm 4 Calculation of the Bray-Curtis distance

Require: Path A , Path B

Ensure: Dissimilarity $d_{BC} \in [0, 1]$

```

1: if  $|A| \neq |B|$  then                                     ▷ Consistency check
2:   return 0
3: end if
4:  $sum\_diff \leftarrow 0$ 
5:  $sum\_total \leftarrow 0$ 
6: for  $k = 1$  to  $|A|$  do
7:    $\Delta_A \leftarrow A[k].j - A[k].i$                            ▷ Budget consumed at time  $k$  of path  $A$ 
8:    $\Delta_B \leftarrow B[k].j - B[k].i$ 
9:    $sum\_diff \leftarrow sum\_diff + |\Delta_A - \Delta_B|$          ▷ More the paths diverge, the more it
      increases
10:   $sum\_total \leftarrow sum\_total + (\Delta_A + \Delta_B)$ 
11: end for
12: if  $sum\_total == 0$  then
13:   return 0
14: end if
15: return  $\frac{sum\_diff}{sum\_total}$ 
  
```

3. Comme vu précédemment, tous les scénarios dépassant le seuil τ_C deviennent des pires scénarios et sont remontés au Maître, donc nous extrayons des chemins qui peuvent se terminer sur des noeuds différents. Il est alors impossible de normaliser par 2Γ .

Maintenant que la notion de distance est définie, il a été nécessaire de trouver une heuristique permettant de chercher les pires chemins dans le graphe. Nous avons opté pour un algorithme de type *Depth-First-Search (DFS)*, il s'agit d'un algorithme glouton de recherche en profondeur qui va (continuer de décrire qu'est ce que cest. type branch and bound?).

Etant donné que nous utilisons la programmation dynamique pour résoudre le sous-problème adverse, l'algorithme connaît le coût maximal à la fin de l'horizon, mais il ne sait pas quel chemin y a mené. Le DFS part donc de la fin et remonte le temps pour retrouver les décisions de l'adversaire.

- Boucle **for** (l.9) : Etant au noeud d'arrivée (période t , budget consommé j), on cherche d'où l'on vient à la période précédente ($t - 1$). La variable i représente le budget qui avait été consommé à l'étape précédente.
Logique : Le budget étant cumulatif, à l'étape précédente on a forcément $0 \leq i \leq j$.
- Condition de Faisabilité (l.10) : Cette ligne vérifie si le chemin ($i \rightarrow j$) à le droit d'exister physiquement dans le graphe. C'est-à-dire que la différence de budget consommé entre les deux périodes ($j - i$) ne peut pas dépasser l'incertitude maximale autorisée à cet instant précis (Δt_{t-1}).
Logique : Si j est trop grand par rapport à i alors on supprime ce sous-arbre.
- Condition Physique pour les arcs de sur-stockage (l.11) : Si nous sommes en sur-stock, l'attaque de l'adversaire va consister à réduire la demande nominale. Aussi, si la demande devient négative, on supprime ce sous-arbre.
- Condition d'Optimalité (l.12/18) : On vérifie si le noeud i fait bien partie du pire scénario. Il va comparer $pi[t][j]$ qui est le coût cumulé maximal pour arriver au noeud actuel et $pi[t][j] + c[t][i][j][0/1]$ qui représente le potentiel du noeud précédent i plus le coût local de la transition ($i \rightarrow j$).
Logique : Si l'égalité est vraie (à ε près), cela prouve que c'est en passant par i que l'on a obtenu le coût maximal $pi[t][j]$.

Algorithm 5 Recursive extraction of worst-case scenarios (DFS)

Require: Period t , Initial budget j , Dual matrix π , Cost matrix c , Nominal solution sol , Current path P_{curr} , Set of paths P_{all} , Limit K , Tolerance ϵ

Ensure: P_{all} updated with the new paths

```

1: if  $|P_{all}| \geq K$  then                                ▷ Stop if the path limit is reached
2:   return
3: end if
4: if  $t == 0$  then                                       ▷ Termination condition : return to the graph's origin
5:    $P_{rev} \leftarrow \text{reverse}(P_{curr})$                  ▷ Reverse the path to get it in the right direction.
6:    $P_{all} \leftarrow P_{all} \cup \{P_{rev}\}$ 
7:   return
8: end if
9: for  $i = 0$  to  $j$  do                                   ▷ Determining the initial budget  $i$ 
10:  if  $j \leq i + sol.\Delta t[t-1]$  and  $(t \neq 1 \text{ or } i == 0)$  then
11:    if  $(j - i) \leq sol.dt[t-1]$  then                 ▷ Verification for type 0 arc (over-storage)
12:      if  $|\pi[t][j] - (\pi[t-1][i] + c[t][i][j][0])| < \epsilon$  then
13:         $P_{curr} \leftarrow P_{curr} \cup \{(t, i, j, 0)\}$ 
14:         $\text{EXTRACT\_PATHS\_DFS}(t-1, i, \pi, c, sol, P_{curr}, P_{all}, K, \epsilon)$ 
15:         $P_{curr} \leftarrow P_{curr} \setminus \{(t, i, j, 0)\}$            ▷ Backtrack
16:      end if
17:    end if
18:    if  $|\pi[t][j] - (\pi[t-1][i] + c[t][i][j][1])| < \epsilon$  then ▷ Verification for the Type 1
    arc
19:       $P_{curr} \leftarrow P_{curr} \cup \{(t, i, j, 1)\}$ 
20:       $\text{EXTRACT\_PATHS\_DFS}(t-1, i, \pi, c, sol, P_{curr}, P_{all}, K, \epsilon)$ 
21:       $P_{curr} \leftarrow P_{curr} \setminus \{(t, i, j, 1)\}$            ▷ Backtrack
22:    end if
23:  end if
24: end for

```

Enfin, nous avons adapté le critère de robustess **MinMax** en prenant en compte les deux éléments cités ci-dessus. L'idée reste de maximiser la distance minimale. Nous fixons N le nombre de scénarios à renvoyer au Maître. Ce paramètre agit davantage comme une borne supérieure. Si l'adversaire ne trouve pas N chemins orthogonaux alors il renverra le maximum de chemins orthogonaux trouvés. L'algorithme 6 se décompose de la façon suivante. On insère le pire scénario absolu P_{opt} qui devient notre référence. Pour la boucle de calcul du plus proche voisin, nous analysons tous les chemins candidats P_{cand} . Si un candidat a une distance min_dist très faible, cela signifie qu'il est très proche d'un autre scénario déjà sélectionné. Ensuite, la boucle **Max** va choisir le candidat dont le plus proche voisin est le plus loin possible.

Algorithm 6 Orthogonality Heuristic (HOG) - Max-Min Selection

Require: Optimal paths P_{opt} , Candidate paths P_{cand} , Number of paths to select N
Ensure: Set of selected orthogonal paths P_{sel}

```

1:  $P_{sel} \leftarrow \emptyset$ 
2: if  $P_{opt} \neq \emptyset$  then      ▷ Locking in the absolute worst-case scenario for the Master.
3:    $P_{sel} \leftarrow P_{sel} \cup \{P_{opt}[0]\}$ 
4: end if
5: while  $|P_{sel}| < N$  and  $P_{cand} \neq \emptyset$  do
6:    $best\_max\_min \leftarrow -1$ 
7:    $best\_candidate \leftarrow \text{null}$ 
8:   for each  $p_c \in P_{cand}$  do                                ▷ Minimization loop
9:      $min\_dist \leftarrow \infty$ 
10:    for each  $p_s \in P_{sel}$  do                                ▷ For each scenario already selected
11:       $dist \leftarrow \text{BRAY\_CURTIS\_DISTANCE}(p_c, p_s)$       ▷ Dissimilarity calculation
12:      if  $dist < min\_dist$  then
13:         $min\_dist \leftarrow dist$ 
14:      end if
15:    end for
16:    if  $min\_dist > best\_max\_min$  then                                ▷ Maximization loop
17:       $best\_max\_min \leftarrow min\_dist$ 
18:       $best\_candidate \leftarrow p_c$ 
19:    end if
20:  end for
21:   $P_{sel} \leftarrow P_{sel} \cup \{best\_candidate\}$ 
22:   $P_{cand} \leftarrow P_{cand} \setminus \{best\_candidate\}$ 
23: end while
24: return  $P_{sel}$ 

```

SOURCE,
sub_OPT
ajouter KC

III.III Résultats

Les différents programmes linéaires ont été résolus avec *CPLEX 20.1.0* et tous les calculs ont été effectués avec un processeur XXXX sous Linux Ubuntu 24.04.4. Pour ces expérimentations, nous avons considéré deux paramètres. Tout d'abord le budget d'incertitude Γ qui prend ses valeurs dans l'ensemble $\{1, 21, 41, 61, 81, 101\}$, ainsi que la méthode de sélection proposée par [6]. Nous avons au total trois méthodes :

BAE : la méthode de Benders adverse standard ;

BAE_{all} : la méthode de Benders adverse étendue, en utilisant la méthode de sélection *SelectAll* ;

BAE_{few} : la méthode de Benders adverse étendue, en utilisant la méthode de sélection *SelectFew*.

Les deux critères qui sont observés sont le nombre d'itérations de l'algorithme ainsi que le temps de calcul pour chacune des méthodes et chacun des Γ . Les résultats sont affichés dans la table XX avec à gauche dans chaque cellule le nombre d'itérations moyen, et à droite le temps de calcul moyen de ces méthodes sur l'ensemble des instances. Pour chaque Γ , les valeurs des cellules avec le plus petit nombre d'itérations moyens ou le plus petit temps de calcul moyen ont été mises en gras.

IV Conclusion

IV.I Synthèse sur le travail effectué

IV.II Apports professionnels

IV.III Apports techniques

Utilisation de l'intelligence artificielle Différents outils d'IA ont été utilisés durant ce stage à des fins d'aide à la compréhension de notions complexes et d'aide pour la correction de code mais n'a pas été moteur de la réflexion.

Bibliographie

- [1] Gabriel R. BITRAN et Horacio H. YANASSE. « Computational Complexity of the Capacitated Lot Size Problem ». In : *Management Science* 28.10 (1982), p. 1174-1186. DOI : 10.1287/mnsc.28.10.1174. URL : <https://ideas.repec.org/a/inm/ormnsc/v28y1982i10p1174-1186.html>.
- [2] J. Roger BRAY et J. T. CURTIS. « An Ordination of the Upland Forest Communities of Southern Wisconsin ». In : *Ecological Monographs* 27.4 (1957), p. 325-349. DOI : <https://doi.org/10.2307/1942268>. eprint : <https://esajournals.onlinelibrary.wiley.com/doi/pdf/10.2307/1942268>. URL : <https://esajournals.onlinelibrary.wiley.com/doi/abs/10.2307/1942268>.
- [3] Romain GUILLAUME, Adam KASPERSKI et Pawel ZIELINSKI. *Robust production planning with budgeted cumulative demand uncertainty*. 2020. DOI : <https://doi.org/10.48550/arXiv.2009.05736>. arXiv : 2009.05736 [cs.DS]. URL : <https://arxiv.org/abs/2009.05736>.
- [4] Zhenbao LIU, Zuren FENG et Liangjun KE. « Fireworks algorithm for the multi-satellite control resource scheduling problem ». In : *2015 IEEE Congress on Evolutionary Computation (CEC)*. 2015, p. 1280-1286. DOI : 10.1109/CEC.2015.7257036.
- [5] Almir MUTAPCIC et Stephen BOYD. « Cutting-set methods for robust convex optimization with pessimizing oracles ». In : *Optimization Methods and Software* 24.3 (2009), p. 381-406. DOI : 10.1080/10556780802712889. URL : <https://doi.org/10.1080/10556780802712889>.
- [6] Tom PORTOLEAU. « Représentations discrètes pour l’ordonnancement et la planification robustes ». Theses. Université toulouse Jean Jaurès, juin 2022. URL : <https://laas.hal.science/tel-04631599>.
- [7] Tom PORTOLEAU, Romain GUILLAUME et Christian ARTIGUES. « Une variante de la méthode de Benders adverse pour le problème de lot-sizing robuste avec budget d’incertitude ». In : *23ème congrès annuel de la Société Française de Recherche Opérationnelle et d’Aide à la Décision*. INSA Lyon. Villeurbanne - Lyon, France, fév. 2022. URL : <https://hal.science/hal-03595446>.
- [8] Julius PÄTZOLD et Anita SCHÖBEL. « Approximate cutting plane approaches for exact solutions to robust optimization problems ». In : *European Journal of Operational Research* 284.1 (2020), p. 20-30. ISSN : 0377-2217. DOI : <https://doi.org/10.1016/j.ejor.2019.11.059>. URL : <https://www.sciencedirect.com/science/article/pii/S0377221719309713>.

-
- [9] C. RICOTTA et J. PODANI. « On some properties of the Bray-Curtis dissimilarity and their ecological meaning ». In : *Ecological Complexity* 31 (2017), p. 201-205. ISSN : 1476-945X. DOI : <https://doi.org/10.1016/j.ecocom.2017.07.003>. URL : <https://www.sciencedirect.com/science/article/pii/S1476945X17300582>.
- [10] Carlo RICOTTA et Sandrine PAVOINE. « A new parametric measure of functional dissimilarity : Bridging the gap between the Bray-Curtis dissimilarity and the Euclidean distance ». In : *Ecological Modelling* 466 (2022), p. 109880. ISSN : 0304-3800. DOI : <https://doi.org/10.1016/j.ecolmodel.2022.109880>. URL : <https://www.sciencedirect.com/science/article/pii/S0304380022000084>.

V Annexes

Preuve. À chaque itération, soit la solution actuelle est optimale, soit une nouvelle coupe (d'optimalité ou de faisabilité) est ajoutée au problème maître. L'espace des coupes possibles étant fini pour un problème linéaire en nombres entiers, l'algorithme ne peut cycliser indéfiniment. ■

Propriété .1: Structure des coupes

Les coupes générées agissent comme des minorants stricts de la fonction objectif dans la région de l'espace explorée.

I Pseudo-code de l'Algorithme

L'environnement algorithm2e est le standard pour les articles scientifiques. Il génère des blocs clairs avec des lignes de structure.

II Implémentation en C++

Pour l'implémentation de nos heuristiques, nous utilisons les fonctionnalités modernes du langage. Le code est indenté et coloré de manière sobre.

Listing 1 – Ajout d'une coupe d'optimalité au solveur

```

1      #include <iostream>
2      #include <vector>
3
4      // Fonction permettant d'ajouter une coupe au modele
5      void addOptimalityCut(Model& masterProblem, const DualSolution&
6          pi, double objVal) {
7          Expr cutExpression;
8
9          // Construction de la coupe basique :  $\theta \geq \pi^T * (b - B * y)$ 
10         for (size_t i = 0; i < pi.size(); ++i) {
11             cutExpression += pi[i] * masterProblem.getSlack(i);
12         }
13
14         // Ajout effectif de la contrainte au probleme maitre
15         masterProblem.addConstraint( masterProblem.getTheta() >=
16             cutExpression );
17
18         std::cout << "Coupe ajoutee avec succes." << std::endl;
19     }
  
```

